

## Distribuição Amostral da Média

A importância da média amostral  $\bar{X}$  surge de seu uso para tirar conclusões sobre a média da população  $\mu$ . A maioria dos procedimentos de inferência, usados com maior frequência, baseiam-se nas propriedades da distribuição de  $\bar{X}$ . A apresentação inicial dessas propriedades foi feita anteriormente através de cálculos e experimentos de simulação.

Proposição Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória ~~de~~ de uma população  $X$ , com  $E(X) = \mu$  e  $\text{Var}(X) = \sigma^2$ . Então,

1-  $E(\bar{X}) = \mu = \mu_{\bar{X}}$

2-  $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$  e  $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$

Além disso, com  $T_0 = X_1 + \dots + X_n$  (o total da amostra),  $E(T_0) = n\mu$ ,  
 $Var(T_0) = n\sigma^2$  e  $\sigma_{T_0} = \sqrt{n}\sigma$ .

Comentário: De acordo com o resultado 1, a distribuição amostral de  $\bar{X}$  é centrada precisamente na média da população da qual a amostra foi selecionada. O resultado mostra que a distribuição de  $\bar{X}$  se torna mais concentrada em torno de  $\mu$  à medida que o tamanho da amostra  $n$  aumenta.

Com diferença marcante, a distribuição de  $T_0$  se dispersa mais ~~quanto~~ à medida que  $n$  aumenta.

## Caso de Distribuição da População Normal (37)

Ao reexaminar o ~~do~~ experimento de simulação, observamos que quando a distribuição da população é normal, cada histograma de valores de  $\bar{x}$  é bem aproximado pela curva normal. Segue o resultado exato.

Proposição Seja  $x_1, x_2, \dots, x_n$  uma amostra aleatória de uma população  $X$  ~~que~~ que segue distribuição normal com média  $\mu$  e desvio padrão  $\sigma$ . Então, para qualquer  $n$ ,  $\bar{X}$  é normalmente distribuído com média  $\mu$  e desvio padrão  $\sigma/\sqrt{n}$ .

~~Logo,  $T_0$  é normalmente distribuído com média  $n\mu$  e desvio padrão  $\sqrt{n}\sigma$ .~~

Além disso,  $T_0$  é normalmente distribuído com média  $n\mu$  e desvio padrão  $\sqrt{n}\sigma$ .

(ir para as  
páginas 8, 9 e 10)  
fgm

Exemplo: O tempo que um rato de determinada subespécie, selecionado aleatoriamente leva para encontrar o caminho em um labirinto é uma variável aleatória distribuída normalmente com  $\mu = 1,5$  min e  $\sigma = 0,35$  min. Suponha que cinco ratos sejam selecionados. Seja  $x_1, \dots, x_5$  seu tempo no labirinto. Assumindo que  $x_i$  é uma amostra aleatória dessa distribuição normal, qual é a probabilidade de tempo total

$T_0 = x_1 + \dots + x_5$  dos cinco estar entre 6 e 8 min?

Resolução: Pela proposição,  $T_0 \sim N(\overbrace{5 \times 1,5}^{7,5}, 5 \times 0,35^2)$

→ PADRONIZAÇÃO de  $T_0$

$$P(6 \leq T_0 \leq 8) = P\left(\frac{6 - 7,5}{\sqrt{5} \cdot 0,35} \leq \frac{T_0 - \mu}{\sqrt{\sigma_{T_0}}} \leq \frac{8 - 7,5}{\sqrt{5} \cdot 0,35}\right)$$

$$= P\left(\frac{6 - 7,5}{0,783} \leq Z \leq \frac{8 - 7,5}{0,783}\right), \text{ onde } Z \sim N(0, 1).$$

$$= P(-1,92 \leq Z \leq 0,64) = \Phi(0,64) - \Phi(-1,92) =$$

$$0,7389 - 0,0274 = 0,7115.$$

(39)



EXERCÍCIO!!

Qual a probabilidade do tempo médio  
da amostra  $\bar{x}$  ser no máximo 2 min?



Combinação Linear

Definição: Dado um conjunto de  $n$  variáveis aleatórias  $X_1, \dots, X_n$  e  $n$  constantes numéricas  $a_1, \dots, a_n$ , a variável aleatória

$$Y = a_1 X_1 + \dots + a_n X_n = \sum_{i=1}^n a_i X_i \quad e$$

denominada combinação linear dos  $X_i$ 's.

Exemplos:  $a_1 = a_2 = \dots = a_n = 1 \Rightarrow Y = X_1 + \dots + X_n = T_0$ .

$$a_1 = a_2 = \dots = a_n = \frac{1}{n} \Rightarrow$$

$$Y = \frac{1}{n} X_1 + \dots + \frac{1}{n} X_n = \bar{X}.$$

{ observe que não é requerido que as  $X_i$ 's sejam independentes ou identicamente distribuídas.

Proposição: Suponha que  $X_1, \dots, X_n$

tenham valores médios  $\mu_1, \dots, \mu_n$ , respectivamente, e variâncias  $\sigma_1^2, \dots, \sigma_n^2$ , respectivamente.

1 - Se os  $X_i$ 's são ou não são independentes,

$$E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i E(X_i) = \sum_{i=1}^n a_i \mu_i.$$

2 - Se  $X_1, \dots, X_n$  são independentes,

$$\text{Var}\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) =$$

$$\sum_{i=1}^n a_i^2 \sigma_i^2.$$

3 - Para qualquer  $X_1, \dots, X_n$ ,

$$\text{Var}(a_1 X_1 + \dots + a_n X_n) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j \text{Cov}(X_i, X_j).$$

## Diferença entre duas Variáveis Aleatórias (50)

Um caso especial importante de combinação linear resulta de  $n=2$ ,  $a_1=1$  e  $a_2=-1$

$$e \quad y = a_1 x_1 + a_2 x_2 = x_1 - x_2$$

Coordenado :  $E(x_1 - x_2) = E(x_1) - E(x_2)$

Se  $x_1$  e  $x_2$  não independentes,

$$\text{Var}(x_1 - x_2) = \text{Var}(x_1) + \text{Var}(x_2)$$

O valor esperado de uma diferença é a diferença entre os dois valores esperados, mas a variância da diferença entre duas variáveis independentes é a soma.

Há tanta variabilidade em  $x_1 - x_2$  como em  $x_1 + x_2$ .



## Caso de Variáveis Aleatórias Normais

(51)

Proposição : Se  $X_1, \dots, X_n$  são v.a.'s independentes, distribuídas normalmente (com médias e/ou variâncias possivelmente diferentes), então qualquer combinação linear de  $X_i$ 's também tem distribuição normal.

Em particular, a diferença  $X_1 - X_2$  entre duas variáveis independentes e normalmente distribuídas é normalmente distribuída.

①

Proposição :

Se  $X_1, \dots, X_n$  são v.a.'s independentes distribuídas normalmente (com médias e/ou variâncias possivelmente diferentes), então qualquer combinação linear dos  $X_i$ 's também tem distribuição normal.

Isto é,

$$Y = \sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right),$$

onde  $X_1, \dots, X_n$  são v.a.'s independentes  $N(\mu_i, \sigma_i^2)$ ,  $i=1, \dots, n$ .

Caso  $X_1, \dots, X_n$  forem iid  $N(\mu, \sigma^2)$ ,

então

$$Y \sim N\left(\mu \sum_{i=1}^n a_i, \sigma^2 \sum_{i=1}^n a_i^2\right) \quad \text{q.}$$

Considerar  $Y = \bar{X} = \frac{X_1 + \dots + X_n}{n}$ , onde

$a_i = 1/n$ ,  $i = 1, \dots, n$ . Temos que

$\bar{X} = Y \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ , como já provamos em sala de aula.

Além disso, considere  $Y = T_0 = X_1 + \dots + X_n$ , onde  $a_i = 1$ ,  $i = 1, \dots, n$ . Temos que

$T_0 = Y \sim N(n\mu, n\sigma^2)$ , como já provamos em sala de aula.

Exatidão?  
 $X_1, \dots, X_n$   
prova via fom



REMEMBRANDO

$X \sim \text{Bernoulli}(p)$

$$m_X(t) = 1 - p + e^{tp}$$

$X \sim \text{Binomial}(n, p)$

$$m_X(t) = (1 - p + e^{tp})^n$$

$X \sim \text{Poisson}(\lambda)$

$$m_X(t) = e^{\lambda(e^t - 1)}$$

EXEMPLO:

$X_1, \dots, X_n$  são  $X \sim \text{Bernoulli}(p)$ . Encontre a distribuição de  $T = \sum_{i=1}^n X_i$ .

Pela propriedade da fgm, temos que

$$m_T(t) = \left[ m_X(t) \right]^n = (1 - p + e^{tp})^n. \text{ Assim,}$$

$$T \sim \text{Binomial}(n, p).$$

$C$  é distribuição de  $\bar{X}$ .

$$m(t) = \left( m_x(t/n) \right)^n = \left( 1-p + e^{t/n} p \right)^n$$

↳ nenhuma distribuição contendo !!

na folhas (54) e (55)

Exemplo:  $X_1, \dots, X_n$  a.a.  $X \sim \text{Poisson}(1)$ .

Encontre a distribuição de  $T = \sum_{i=1}^n X_i$ .

$$m_T(t) = \left( m_X(t) \right)^n =$$

$$\left[ e^{1(e^{t/n}-1)} \right]^n = e^{n(e^{t/n}-1)}$$

$T \sim \text{Poisson}(n)$

na folhas (54) e (55)



# Distribuição Exata da média amostral (2)

## para alguns casos específicos !!

Exemplo 1 : Se  $X_1, \dots, X_n$  é uma amostra aleatória de uma população  $X$  que segue uma distribuição de Bernoulli ( $p$ ).  
Desejamos encontrar a distribuição exata de  $\bar{X}$ .

Resolução :  $X \sim \text{Bernoulli}(p)$ , então

$$p(x) = p^x (1-p)^{1-x} \cdot \underbrace{I(x)}_{(0,1)} \rightarrow I(x) = \begin{cases} 1 & \text{se } x=0 \text{ ou } 1 \\ 0 & \text{c.c.} \end{cases}$$

Sabemos que  $\sum_{i=1}^n X_i \sim \text{Binomial}(n, p)$ , isto é,

$$P\left(\sum_{i=1}^n X_i = k\right) = \binom{n}{k} p^k (1-p)^{n-k} \cdot \underbrace{I(k)}_{(0,1,\dots,n)}$$

$$P(\bar{X} = y) = P\left(\sum_{i=1}^n X_i = \underbrace{ny}_{K}\right) = \binom{n}{K} (1-p)^{n-K} I(K) \quad (93)$$

(0, 1, ..., n),

$$ny = K \Rightarrow \underbrace{y = K/n}$$

tal que a distribuição amostral de  $\bar{X}$  é obtida da distribuição de  $\sum_{i=1}^n X_i$ .

Portanto, a média amostral proveniente de uma amostra aleatória retirada de uma população com distribuição Bernoulli, assume os valores

0,  $\frac{1}{n}$ ,  $\frac{2}{n}$ , ..., 1 com as respectivas probabilidades

$$\binom{n}{0} p^0 q^n, \quad \binom{n}{1} p^1 q^{n-1}, \quad \binom{n}{2} p^2 q^{n-2}, \dots,$$

$$\binom{n}{n} p^n q^0, \text{ onde } q = 1-p.$$

Exemplo 2: Se  $X_1, \dots, X_n$  é uma amostra aleatória de uma população  $X$  que segue uma distribuição de Poisson(1), então sabemos que  $\sum_{i=1}^n X_i \sim \text{Poisson}(n)$ . Assim,

$$P(X) = \frac{e^{-1} 1^x}{x!} \quad I(x) \\ (0, 1, 2, \dots)$$

$$P\left(\sum_{i=1}^n X_i = K\right) = \frac{e^{-n} (n)^K}{K!} \quad I(K) \\ (0, 1, 2, \dots)$$

$$P\left(\bar{X} = y\right) = P\left(\sum_{i=1}^n X_i = \underbrace{ny}_K\right) = \frac{e^{-n} (n)^K}{K!} I(K) \\ (0, 1, 2, \dots)$$

onde  $y = K/n$ . Portanto, a média amostral proveniente de uma amostra aleatória retirada de uma população com distribuição Poisson, assume os valores

$0, \frac{1}{n}, \frac{2}{n}, \dots$ , com as respectivas probabilidades

$$\frac{e^{-n\lambda} (n\lambda)^0}{0!},$$

$$\frac{e^{-n\lambda} (n\lambda)^1}{1!},$$

$$\frac{e^{-n\lambda} (n\lambda)^2}{2!}, \dots$$

(55)

A distribuição amostral de  $\bar{x}$  é obtida  
da distribuição de  $\sum_{i=1}^n x_i$ .