

Na próxima aula, consideramos a relação entre estatísticas suficientes e auxiliares.

Limite de completude para $\theta \in \text{ENVVMU}(\text{UMVUE})$ (termo adicional)

Estatísticas suficientes, auxiliares e completas.

melhor estimador

Mood, Casella e Berger

Definição: (completude)

(e pode ser vista)

Seja X_1, \dots, X_n a.a. $X \sim f(\cdot | \theta)$, $\theta \in \Theta$ e seja

$T = T(X_1, \dots, X_n)$ uma estatística. A família de distribuições de T é dita ser completa se e somente se

$$E[g(T)] = 0 \quad \forall \theta \in \Theta \quad \text{e que implica}$$

que $P(g(T) = 0) = 1 \quad \forall \theta \in \Theta$, onde $g(T)$

é uma estatística. Além disso, a estatística T é dita ser completa se e somente se sua família de distribuições é completa.

Comentários: 1- Outra forma de dizer que T é completa é a seguinte:
a estatística T é completa se e somente se

ou seja,

o único estimador não viciado de θ que $\textcircled{7}$
é função de T é a estatística ~~estatística~~ identi-
camente nula (com probabilidade 1).

→ está

x- Observe que o conceito de completude
é relativo a uma família de distribuições,
não de uma distribuição em particular.

Por exemplo, se $T \sim N(0, 1)$, então definindo

$$g(t) = t, \text{ temos que } E[g(T)] = E[T] = 0,$$

mas a função $g(t) = t$ satisfaz $P(g(T) = 0) =$

$$P(T = 0) = 0, \text{ não } 1. \text{ Todavia, esta é uma}$$

distribuição específica e não uma família de
distribuições. Se $T \sim N(\theta, 1)$, $\theta \in \mathbb{R}$, devemos

observar que nenhuma função de T , exceto uma
que seja 0 com probabilidade 1 para todo θ ,

$$\text{satisfaz } E[g(T)] = 0, \forall \theta. \text{ Portanto, a}$$

família de distribuições $N(\theta, 1)$, $\theta \in \mathbb{R}$, é
completa.

Vejamos alguns exemplos!!

Devemos observar que nenhuma função de T ,
exceto uma que seja 0 com probabilidade 1,
para todo θ , satisfaz $E[g(T)] = 0 \quad \forall \theta \in \Theta$.

Esta propriedade significa que duas quaisquer funções da estatística $T(\cdot)$ que tenham a mesma média para todo o parâmetro $\theta \in \Theta$ são idênticas com probabilidade 1.

(ideia de ortogonalidade \rightarrow disenter na matemática) !

\hookrightarrow pensamos nos discretos

$$\sum_{t_0}^{\infty} g(t) p(t)$$


pode ser visto

onde

$$p(t) = p(x=t)$$

como um produto interno dos vetores

$$(g(t_1), g(t_2), g(t_3), \dots) \text{ e } (p(t_1), p(t_2), p(t_3), \dots)$$



esses dois vetores são ortogonais!

ver. arquivos complex-math

Exemplo 1: Seja x_1, \dots, x_n e $x \sim \text{Bernoulli}(\theta)$.

Mostre que $T = \sum_{i=1}^n x_i$ é uma estatística

completa. $\downarrow T \sim \text{Binomial}(n, \theta)$

Lembrete:

Pela definição, temos que a família de distribuições de T é dita ser completa se e somente se

$$E[g(T)] = 0 \quad \forall \theta \in \Theta \text{ o que implica}$$

que $P(g(T)=0) = 1 \quad \forall \theta \in \Theta$, onde $g(t)$ é uma estatística.

$T \text{ é completa} \iff \text{sua família de distribuições é completa}$

Portanto, temos que mostrar que

$$E[g(T)] = \sum_{t=0}^n g(t) \binom{n}{t} \theta^t (1-\theta)^{n-t} = 0, \quad \forall \theta \in \Theta,$$

o que implica que $P(g(T)=0) = 1, \forall \theta \in \Theta$.

Note que $E[g(T)] = (1-\theta)^n \sum_{t=0}^n g(t) \binom{n}{t} \left(\frac{\theta}{1-\theta}\right)^t =$

$$(1-\theta)^n \sum_{t=0}^n g(t) \binom{n}{t} \alpha^t, \text{ onde } \alpha = \frac{\theta}{1-\theta} \quad \text{e} \quad (9)$$

$$\alpha \in (0, \infty), \text{ sei } (A) = \{0, \theta \in (0, 1)\}.$$

Assim, $E[g(T)] = 0 \Leftrightarrow$

$$(1-\theta)^n \sum_{t=0}^n g(t) \binom{n}{t} \alpha^t = 0 \quad \Leftrightarrow$$

$$\sum_{t=0}^n g(t) \binom{n}{t} \alpha^t = 0. \quad \text{Note que}$$

para um polinômio em α ser identicamente 0, cada coeficiente de α^t , $t=0, \dots, n$, deve ser 0, isto é,

$$g(t) \binom{n}{t} = 0 \quad \text{para } t=0, \dots, n. \quad \text{Porém, note}$$

que $\binom{n}{t} \neq 0$ e então, $g(t) = 0$, para $t=0, \dots, n$, $t \in (A)$

Portanto, T é uma estatística completa.

Dado que $T(X) \in \{0, 1, \dots, n\}$ não segue que $g(T(X)) = 0$ com probabilidade 1.

X_1, \dots, X_n e $X \sim \text{Bernoulli}(0)$ ou $X \sim N(0, 1)$

Pergunta: A estatística $T = X_1 - X_\alpha$ é

completa?

(10)

Note que $E(T) = E(X_1 - X_\alpha) = E(X_1) - E(X_\alpha) = 0$

e $X_1 - X_\alpha \stackrel{\sim}{=} 0$ com probabilidade 1.

Portanto, $T = X_1 - X_\alpha$ não é uma estatística

completa. $\rightarrow X_1 - X_\alpha \sim N(0, 2)$ $P(X_1 - X_\alpha = 0) = 0.$

Teorema Fundamental do Cálculo

Parte I

Se f é contínua em $[a, b]$, então a função F definida por

$$F(x) = \int_a^x f(t) dt \quad (\text{com } a \leq x \leq b)$$

é contínua em $[a, b]$, diferenciável em (a, b) e

$$F'(x) = f(x).$$

A derivada de F corresponde a função f que aparece no integrando. Observa-se que as operações integrais e derivadas são operações inversas.

Parte II

nos permite calcular áreas

Se f é contínua em $[a, b]$, então

$$\int_a^b f(x) dx = F(b) - F(a) \quad \text{sendo } F \text{ uma}$$

anti-derivada de f . Isto é, $F'(x) = f(x)$.

estabelece a conexão entre o Cálculo Diferencial e o Cálculo Integral

92

Exemplo 2: Seja X_1, \dots, X_n e $X \sim U(0, \theta)$, $\theta > 0$.

Mostre que $T = X_{(n)}$ é uma estatística completa.

Necessamos mostrar que se $E[g(T)] = 0 \forall \theta > 0$,
então $P(g(T) = 0) = 1 \forall \theta > 0$.

Note que conhecemos a distribuição de $T = X_{(n)}$.

$$P(T \leq t) = P(\max\{X_1, \dots, X_n\} \leq t) = P(X_1 \leq t, \dots, X_n \leq t) = \\ P(X_1 \leq t) \dots P(X_n \leq t) \stackrel{\text{id}}{=} [P(X \leq t)]^n = \left[F_X(t)\right]^n =$$

$$\left(\frac{t}{\theta}\right)^n,$$

$0 < t < \theta$, ou seja,

$$F_T(t) = \begin{cases} 0 & \text{se } t \leq 0 \\ \left(\frac{t}{\theta}\right)^n & \text{se } 0 < t < \theta \\ 1 & \text{se } t \geq \theta \end{cases}$$

$$f_T(t) = \frac{n}{\theta^n} t^{n-1} \quad \text{re} \quad 0 < t \leq \theta. \quad (11)$$

com efeito,

$$E[g(T)] = \int_0^\theta g(t) \cdot \frac{n}{\theta^n} t^{n-1} dt = 0, \quad \forall g \in \mathcal{H}. \quad (14)$$

Assim,

$$\int_0^\theta g(t) \frac{n}{\theta^n} t^{n-1} dt = 0 \quad \Leftrightarrow$$

$$(14) \quad \left(\int_0^\theta g(t) t^{n-1} dt = 0, \quad \forall g \in \mathcal{H} \right).$$

Dividindo a expressão acima por θ^n e considerando o respeito a θ ,

tem-se que

$$g(\theta) \theta^{n-1} = 0, \quad \text{pois} \quad \text{para } \theta \in \mathcal{H} \quad \text{ver acima}$$

Teorema Fundamental do Cálculo

Portanto, $E[g(T)] = 0, \quad \forall g \in \mathcal{H}, \quad \text{re} \quad \theta \in \mathcal{H}$

$$g(\theta) \theta^{n-1} = 0, \quad \forall \theta \in \textcircled{H} \quad \Leftrightarrow$$

12

$$g(\theta) = 0, \quad \forall \theta \in \textcircled{H} \quad \Rightarrow$$

$$\textcircled{H} = \{\theta, \theta > 0\}$$

$$g(t) = 0, \quad \forall t \text{ valor de } T \Rightarrow g(t) = 0, \quad \forall \theta \in \textcircled{H}.$$

Portanto, $T = X_{(n)}$ é estatística completa.

Exemplo

Discussão no Correla em formato de exercício!

(12/2)

X_1, \dots, X_n a.a. $X \sim U(\theta, \theta+1)$.

Já vimos que $T(\underline{X}) = (X_{(1)}, X_{(n)})$ é estatística conjuntamente suficiente minimal para θ , mas T não é completa.

Já vimos que a família $U(\theta, \theta+1)$ é família linear e $R = X_{(n)} - X_{(1)}$ é estatística auxiliar, portanto sua distribuição não depende de θ .

Assim,

$$E(X_{(n)} - X_{(1)}) = c \quad \hookrightarrow \text{que não depende de } \theta$$

$$E(X_{(n)} - X_{(1)} - c) = 0 \quad \forall \theta \in \Theta$$

$$P(X_{(n)} - X_{(1)} - c = 0) \neq 1 \quad \forall \theta \in \Theta.$$

Assim, ^{condição} $g(T) = X_{(n)} - X_{(1)} - c$, vimos que T não é completa.

2/b

Este problema pode ser generalizado para mostrar
que se a função de estatística suficiente é
única, então a estatística suficiente não é completa,
porque a esperança da função não depende de θ .

Isto fornece a oportunidade para construir um
estimador ^{não nulo} não viciado de θ .

Em geral, demonstrar a completude é um problema de análise realmente difícil. O teorema a seguir terá uma ferramenta útil para argumentar a completude.

Teorema : (Estatísticas completas na família exponencial)

Sejam x_1, \dots, x_n observações i.i.d de uma família exponencial k -paramétrica com f.p ou f.d.p na forma

$$f(\underline{x} | \underline{\theta}) = h(\underline{x}) c(\underline{\theta}) \exp \left\{ \sum_{i=1}^n w_i(\underline{\theta}) t_i(x) \right\},$$

onde $\underline{\theta} = (\theta_1, \dots, \theta_k)$. Então, a estatística, associada à amostra,

$$T(\underline{x}) = \left(\sum_{j=1}^n t_1(x_j), \sum_{j=1}^n t_2(x_j), \dots, \sum_{j=1}^n t_k(x_j) \right) e^{-}$$

completa desde que o espaço paramétrico
 contenha um retângulo de \mathbb{R}^K (13) (2)
em outras palavras, que um conjunto aberto em \mathbb{R}^K

\Rightarrow condição necessária, mas não suficiente

$\neq ?$

Comentários:

(14) contém um retângulo K -dimensional Δ em, (4) $\subseteq \mathbb{R}^K$

* A família de distribuições $N(\mu, \sigma^2)$
 tem como $\Theta = \{(\mu, \sigma^2) \mid \mu \in \mathbb{R} \text{ e } \sigma^2 > 0\}$, ou seja, $\Theta = \{(\mu, \sigma^2) = \mathbb{R} \times (0, \infty)\}$.

\Rightarrow Note que a família de distribuições $N(\mu, \sigma^2)$ pertence à família exponencial K -paramétrica, onde $K=2$. Como $\Theta =$

$\mathbb{R} \times \mathbb{R}_+$ contém um retângulo de \mathbb{R}^2 então

$T(\underline{X}) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$ é completa \Leftrightarrow

uma família de distribuições é completa.

Lembrete: Definição (Completude)

A estatística T é dita ser completa se e somente se uma família de distribuições é completa

* A família de distribuições $N(\mu, \sigma^2)$ tem como $\Theta = \{(\mu, \sigma^2) = (\mu, \sigma^2), \mu \in \mathbb{R}, \sigma^2 > 0\}$ ou seja, o espaço paramétrico consiste nos pontos em uma parábola.

\Rightarrow Note que a família de distribuições $N(\mu, \sigma^2)$ é uma família exponencial curva e o espaço paramétrico não contém um retângulo de \mathbb{R}^2 , então não posso afirmar que

$$T(X_{\sim}) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right) \text{ é completa !!}$$

Para provar que é ou não completa, teríamos que usar a definição.

$$\begin{aligned} \text{Porém, note que } E[g(T)] &= E\left[\frac{\bar{X}_n}{n+1} - S^2\right] \\ &= \frac{n}{n+1} E[\bar{X}^2] - E[S^2] = \frac{n}{n+1} \left(\frac{\sigma^2}{n} + \sigma^2\right) - \sigma^2 \\ &= \frac{n\sigma^2}{n+1} + \frac{n\sigma^2}{n+1} - \sigma^2 = \sigma^2 \left(\frac{1}{n+1} + \frac{n}{n+1} - 1\right) = 0 \end{aligned}$$

$$\theta^2 \left[\frac{1 + n - (n+1)}{n+1} \right] = 0 \quad e$$

$q(\tau)$ não é identicamente nula, pois

$$\bar{X} \sim N\left(\theta, \frac{\theta^2}{n}\right) \quad e \quad \frac{(n-1)S^2}{\theta^2} \sim \chi^2_{n-1}$$

(13) (d)

* $N(\mu, \tau^2)$ é uma subfamília de $N(\mu, \sigma^2)$.

(13) (C)

* Ao restringir a família (trabalhar com subfamília) podemos perder consistência, o que não ocorre com suficiência. Ao trabalhar com subfamília ainda mantemos suficiência.

Resultado útil

(13) d

$$\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2. \quad \text{Logo, considere}$$

X_1, \dots, X_n a.a. $X \sim N(\mu, \sigma^2)$ e assim, temos que

$$\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2 + \frac{1}{\sigma^2} n(\bar{x} - \mu)^2. \quad \text{Note que}$$

$$\sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2 \sim \chi_n^2 \quad \text{e} \quad \frac{(\bar{x} - \mu)^2}{(\sigma/\sqrt{n})^2} \sim \chi_1^2. \quad \text{Portanto,}$$

$$\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Teorema redundante: estatística suficiente
mínima e completa. Note pelo teorema
abaixo que uma propriedade fundamental
de uma estatística completa é o fato de
que ela é mínima.

Teorema: Se uma estatística suficiente
mínima existe, então qualquer estatística
suficiente completa é mínima.

PROVA: Seja $T(\underline{x})$ uma estatística suficiente
e completa para θ . Além disso, vamos supor
que existe uma ^{outra} estatística suficiente
~~tal que~~ $T_1 = p(T)$. Portanto, $T_1(\underline{x})$
é uma estatística suficiente mínima.
Lembrete

uma estatística suficiente $T_1(\underline{x})$ é chamada
estatística suficiente mínima se, para qualquer
outra estatística suficiente $T(\underline{x})$, $T_1(\underline{x})$
é uma função de $T(\underline{x})$.

~~Seja~~ $g(T) = T - (E(T|T_1))$ uma
estatística, tal que

$$E[g(T)] = E[T - E(T|T_1)] = E(T) - E[E(T|T_1)]$$

$$= E(T) - E(T) = 0. \quad T(X) \text{ é completa (TS)}$$

$$\text{se } E[g(T)] = 0 \quad \forall \theta \in \Theta, \theta \text{ que implica}$$

$$P(g(T) = 0) = 1 \quad \forall \theta \in \Theta. \quad \text{Assim,}$$

$$P(g(T) = 0) = P(T - E(T|T_1) = 0) =$$

$$P(T = E(T|T_1)) = 1, \text{ ou seja,}$$

$$P(T = \psi(T_1)) = 1. \quad \text{Portanto,}$$

T é uma estatística suficiente mínima.

Provas o seguinte !!

T é uma função de T_1 e T_1 é uma função de $T \Rightarrow T_1$ e T são estatísticas equivalentes.

Se T é suficiente completa não pode existir esta estatística suficiente que não seja função biunívoca de T .

$E(T|T_1)$ é uma estatística, pois T é
uma estatística (função da amostra) e T_1
é suficiente. Portanto, pela definição de
estatística suficiente, temos que a distribuição
condicional de X_1, \dots, X_n dado $T=t$ não depende de θ .