

Unidade II

Princípios da Redução de dados

①

Introdução



* Um pesquisador (experimentador) utiliza as informações em uma amostra X_1, \dots, X_n para fazer inferências (problemas da inferência: estimação e testes de hipóteses) sobre um parâmetro desconhecido.

* Se o tamanho da amostra n for grande, então a amostra observada X_1, \dots, X_n consiste de uma longa lista de números que podem se tornar difíceis de se interpretar.

* Uma das áreas da Estatística é a Análise Exploratória de dados ou Estatística

descritiva, cujo objetivo é resumir as informa-

ções em uma amostra determinando algumas características importantes (medidas resumo ou estatísticas descritivas), tais como a média amostral, a variância amostral, a menor e a maior observação.

* Observe que o resumo dos dados, em geral, ⁽²⁾
é feito por meio de estatísticas, qualquer
função da amostra que não depende de parâ-
metros desconhecidos.

* A estatística é uma variável aleatória
que condensa n variáveis aleatórias X_1, \dots, X_n
em uma única variável aleatória. Tal
condensação é atenta uma vez que trabalhar
com quantidades unidimensionais é melhor
(mais fácil) do que com quantidades
multidimensionais.

~~LD~~ ~~(XX)~~ ~~conveniência~~ ~~extros~~ ~~(modos)~~ ~~região~~ ~~(300)~~ ~~(2)~~ ~~(3)~~

* Estudaremos um princípio de redução de dados
conhecido como princípio da suficiência.

* Estamos interessados em métodos de redução
de dados que não desconsiderem informações
importantes sobre o parâmetro desconhecido θ
e em métodos que descartem, de forma bom-
suada, informações que sejam irrelevantes
para a obtenção de conhecimento sobre θ
que se refere.

suporte da distribuição

Amostras

A contagem pode ser visualizada também de uma outra forma.

Considere que X denote a gama de valores que (X_1, \dots, X_n) podem assumir. Por exemplo, se nós amostramos de uma distribuição Bernoulli, então X é a coleção de todos os vetores n dimensionais com componentes 0 e 1.

Note que uma estatística induz ou define uma partição de X . (Lembrando a definição de partição de X é

uma coleção de subconjuntos mutuamente exclusivos (disjuntos) de X , tais que a união deles é o X). Considere $t(., \dots, .)$ como sendo a função correspondente (correspondendo) à estatística $T = t(X_1, \dots, X_n)$. A partição induzida ou definida por $t(., \dots, .)$ é a seguinte:

Considere t_0 qualquer valor da função $t(., \dots, .)$; que o subconjunto de X consistindo de todos aqueles pontos (x_1, \dots, x_n) para os quais $t(x_1, \dots, x_n) = t_0$ é um subconjunto na coleção dos subconjuntos dos quais a partição composta é formada e é definida; outros subconjuntos são similarmente formados considerando outros valores de $t(., \dots, .)$. Por exemplo, se uma amostra de tamanho 3 é selecionada da distribuição Bernoulli, então

X consiste de oito pontos $(0, 0, 0), (0, 0, 1),$

11

$(0, 1, 0), (1, 0, 0), (0, 1, 1), (1, 0, 1), (1, 1, 0),$
 $(1, 1, 1)$. Considere $f(x_1, x_2, x_3) = x_1 + x_2 + x_3$;

então $f(\cdot, \cdot, \cdot)$ toma (assume) os valores
 $0, 1, 2, 3$. A partição de X induzida por
 $f(\cdot, \cdot, \cdot)$ consiste de 4 subconjuntos

$\left\{ \underbrace{(0, 0, 0)}_{1-9}, \underbrace{\{(0, 0, 1), (0, 1, 0), (1, 0, 0)\}}_{2-9}, \right.$
 $\left. \underbrace{\{(0, 1, 1), (1, 0, 1), (1, 1, 0)\}}_{3-9}, \underbrace{\{(1, 1, 1)\}}_{4-9} \right\}$

correspondendo, respectivamente, aos quatro
valores $0, 1, 2$ e 3 de $f(\cdot, \cdot, \cdot)$. A
estatística então é realmente uma
condensação de X . Neste exemplo acima,
se não usarmos a estatística $f(\cdot, \cdot, \cdot)$,
teríamos que nos preocupar apenas com
4 diferentes valores ao invés de 8 diferentes
pontos de X .

Observe que diferentes estatísticas podem
induzir a mesma partição. De fato, se
 $f(\cdot, \cdot, \cdot)$ é uma estatística, então qualquer
função h de f (bijetora) de f tem a
mesma partição como f . No exemplo acima,
 $f'(x_1, x_2, x_3) = 6(x_1 + x_2 + x_3)$ ou $f''(x_1, x_2, x_3) =$
 $x_1^2 + x_2^2 + x_3^2$ induzem a mesma partição de

$$T(x_1, x_2, x_3) = x_1 + x_2 + x_3.$$

Uma das regras para usar estatísticas é que elas fazem a condensação (condensam) X e se essa é a regra única regra para usar estatística, então quaisquer duas estatísticas com a mesma partição são de mesma utilidade. O importante aspecto da estatística é a partição de X que ela induz, não os valores que elas assumem.

A estatística suficiente é um tipo particular de estatística. É uma estatística que condensa X de tal forma que não perde informação sobre "o".

↳ parâmetro de interesse.

Princípio da Suficiência

Promove um método de redução de dados que não descarta informações sobre θ ao obter algum resumo dos dados.

Uma estatística suficiente para um parâmetro θ é uma estatística que, de certa maneira, capta todas as informações sobre θ contidas na amostra. Quaisquer outras informações adicionais na amostra, além do valor da estatística suficiente, não apresentam mais nenhum detalhe sobre θ .

Princípio da Suficiência

Se $T(\underline{x})$ é uma estatística suficiente para θ , então qualquer inferência sobre θ deve depender da amostra \underline{x} somente pelo valor $T(\underline{x})$.

Isso é, se \underline{x} e \underline{y} são dois pontos amostrais, de modo que $T(\underline{x}) = T(\underline{y})$, então a inferência sobre θ deve ser a mesma, se $\underline{x} = \underline{x}$ ou $\underline{x} = \underline{y}$ for observado.

Uma estatística suficiente é formalmente definida da seguinte maneira.

Definição : (Estatística Suficiente)

①

Seja X_1, \dots, X_n a.a. $X \sim f(\cdot | \theta)$, $\theta \in \Theta$, onde $f(\cdot | \theta)$ pode ser a f.d.p. (caso contínuo) ou a f.p. (caso discreto). Dizemos que uma estatística $S = S(X_1, \dots, X_n)$ é suficiente para θ se e somente se a distribuição condicional de X_1, \dots, X_n dado $S = s$ não depende de θ para qualquer valor s de S .

→ conveniência
atras

Os exemplos a seguir ilustram a obtenção de estatísticas suficientes pela utilização da definição.

Exemplo 1 : Seja X_1, X_2, X_3 uma a.a. de tamanho 3 proveniente da distribuição Bernoulli(p). Mostre que $S = S(X_1, X_2, X_3) = X_1 + X_2 + X_3$ é suficiente para p .

X	s (valor de S)	$f(X_1, X_2, X_3)$ $f(X_1, X_2, X_3 S = s)$
$(0, 0, 0)$	0	1
$(0, 0, 1)$	1	$\frac{1}{3}$
$(0, 1, 0)$	1	$\frac{1}{3}$

$(1, 0, 0)$	1	$\frac{1}{3}$
$(0, 1, 1)$	2	$\frac{1}{3}$
$(1, 0, 1)$	2	$\frac{1}{3}$
$(1, 1, 0)$	2	$\frac{1}{3}$
$(1, 1, 1)$	3	1

Note que $f(0, 1, 0 | 1) =$
 $x_1, x_2, x_3 | S = 1$

$$P(X_1=0, X_2=1, X_3=0 | S=1) = \frac{P(X_1=0, X_2=1, X_3=0, S=1)}{P(S=1)} =$$

$$\frac{P(X_1=0, X_2=1, X_3=0)}{P(S=1)} = \frac{P(X_1=0) P(X_2=1) P(X_3=0)}{P(S=1)},$$

onde $S \sim \text{Binomial}(3, p)$.

$$= \frac{(1-p) p (1-p)}{\binom{3}{1} p (1-p)^2} = \frac{1}{3}.$$

Portanto, S é suficiente para p , pois a distribuição condicional da amostra dada os valores de S // independe // de p . \rightarrow DVS
 ites

Exemplo 2 : Seja X_1, \dots, X_n a.a. $X \sim \text{Bernoulli}(p)$.

Mostre que $S = S(X_1, X_2, \dots, X_n) = \sum_{i=1}^n X_i$ e $\textcircled{3}$
 uma estatística suficiente para p .

Preciso mostrar que

$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n \mid S(X_1, \dots, X_n) = s)$
 independe de p .

Sabe-se que $f(x_1, \dots, x_n \mid p) = \prod_{i=1}^n$

$$p^x (1-p)^{1-x} \quad \mathbb{I}_{\{0,1\}}(x) = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i} \prod_{i=1}^n \mathbb{I}_{\{0,1\}}(x_i)$$

Assim, $P(\tilde{X} = \tilde{x} \mid S(\tilde{X}) = s) =$

$$P(X_1 = x_1, \dots, X_n = x_n \mid \sum_{i=1}^n X_i = s) =$$

$$P(X_1 = x_1, \dots, X_n = x_n, \sum_{i=1}^n X_i = s)$$

$$P(\sum_{i=1}^n X_i = s)$$

$$\frac{P(X_1 = x_1) P(X_2 = x_2) \dots P(X_n = x_n)}{P(\sum_{i=1}^n X_i = s)} \quad \text{se } \sum_{i=1}^n x_i = s$$

$$= \left\{ \frac{p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}}{\binom{n}{s} p^s (1-p)^{n-s}} \prod_{i=1}^n I_{(x_i)} \right\} \mathcal{N} \sum_{i=1}^n x_i = s$$

$$\{0, 1\}$$

$$\{0, 1, \dots, n\}$$

$$= \left\{ \frac{1}{\binom{n}{s}} \frac{\prod_{i=1}^n I_{(x_i)} \{0, 1\}}{I(s) \{0, 1, \dots, n\}} \right\} \mathcal{N} \sum_{i=1}^n x_i = s$$

$\Rightarrow s$ é suficiente para p .

Exemplo 3 : Seja X_1, \dots, X_n aa X_i parâmetro θ ⑤

Mostre que $S = S(X_1, \dots, X_n) = \sum_{i=1}^n X_i$ é

uma estatística suficiente para θ .


$$P(X_{\sim} = x_{\sim} \mid S(x_{\sim}) = \lambda) = \frac{P(X_{\sim} = x_{\sim}, S(x_{\sim}) = \lambda)}{P(S(x_{\sim}) = \lambda)} =$$

$$\frac{P(X_1 = x_1, \dots, X_n = x_n, \sum_{i=1}^n X_i = \lambda)}{P(\sum_{i=1}^n X_i = \lambda)} =$$

$$P\left(\sum_{i=1}^n X_i = \lambda\right)$$

$$\left\{ \begin{array}{l} \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{x_i!} \quad I(x_{\sim}) \quad \text{se} \quad \sum_{i=1}^n x_i = \lambda \\ \frac{e^{-n\theta} (n\theta)^\lambda}{\lambda!} \quad \bar{I}(\lambda) \quad \{0, 1, \dots\} \end{array} \right.$$

6



$$\prod_{i=1}^n I(x_i)$$

$$\{0, 1, \dots\}$$

$$N \sum_{i=1}^n x_i = \Delta$$

$$\prod_{i=1}^n x_i !$$



$$I(\lambda)$$

$$\{0, 1, \dots\}$$

$$\lambda !$$

C C

0

$$= \prod_{i=1}^n I(x_i)$$

$$\{0, 1, \dots\}$$

$$\lambda !$$

$$N \sum_{i=1}^n x_i = \Delta$$

$$\prod_{i=1}^n x_i !$$

$$n^{\Delta} I(\lambda)$$

$$\{0, 1, \dots\}$$

C C

0

Logo, Δ é suficiente para θ .

Exemplo 4: Seja X_1, \dots, X_n a.a $X \sim \exp(1)$. (7)

Mostre que $S = \sum_{i=1}^n X_i$ é uma estatística suficiente para λ .

$$f(x_1, \dots, x_n | \sum_{i=1}^n x_i = A) = \frac{f(x_1, x_2, \dots, x_n, A)}{f_n(A)}$$

$$\left\{ \begin{array}{l} \prod_{i=1}^n \lambda e^{-\lambda x_i} I(x_i) \\ (0, \infty) \end{array} \right. \quad \text{se} \quad \sum_{i=1}^n x_i = A$$

$$\left\{ \begin{array}{l} f(t) \\ \sum_{i=1}^n x_i \\ 0 \end{array} \right. \quad c.c$$

Note-se que $\sum_{i=1}^n X_i \sim \text{Gamma}(n, 1)$ Portanto,

$$= \left\{ \frac{\lambda^n e^{-\lambda \sum_{i=1}^n x_i} \prod_{i=1}^n I(x_i)}{\lambda^n / \Gamma(n) e^{-\lambda A} I(A)} \right. \quad \text{se} \quad \sum_{i=1}^n x_i = A$$

{ 0

c c

3

$$= \left\{ \begin{array}{l} \prod_{i=1}^n \overline{I}(x_i) \\ (0, \infty) \end{array} \right. \quad \Gamma(n)$$

$n-1$
 λ
 0

$$\mathcal{N} \quad \sum_{i=1}^n x_i = \lambda$$

c c

Logo, $\sum_{i=1}^n x_i$ é suficiente para λ .

Notemos que a Definição permite, apenas, que possamos verificar se determinada estatística é ou não suficiente. Contudo não pode ser utilizada como um método para obtenção de estatísticas suficientes. Um procedimento para a obtenção de estatísticas suficientes é o critério da fatoração que apresentamos a seguir.

Teorema : (critério da Fatoração de Neyman) (12)

Seja x_1, \dots, x_n uma amostra aleatória da distribuição da variável aleatória X com função densidade (ou de probabilidade) $f(x|\theta)$. Uma estatística $S = S(x_1, \dots, x_n)$ é a estatística suficiente para θ se, e somente se, existem funções $g(s|\theta)$ e $h(x_1, \dots, x_n)$ de modo que, para todos os pontos amostrais $\underline{x} = (x_1, \dots, x_n)$, e todos os pontos de parâmetro θ ,

$$f(x_1, \dots, x_n|\theta) = g(S(x_1, \dots, x_n)|\theta) h(x_1, \dots, x_n)$$

$$= \underbrace{g(S|\theta)}_{\text{função não negativa}} h(x_1, \dots, x_n).$$

Comentários: Para utilizar o critério da fatoração a fim de encontrar uma estatística suficiente, fatoramos a f.d.p. conjunta da amostra em duas partes, sendo que uma parte não depende de θ . Esta parte constitui a função $h(x_1, \dots, x_n)$. A outra, dependente de θ , igualmente depende da amostra

x_1, \dots, x_n somente por meio de alguma função $S(x_1, \dots, x_n)$, e esta função é uma estatística suficiente para θ .

(13)

PROVA : Casella e Berger pag 245
Belfarine pag 22

(ideia: utilizar a Definição de estatística suficiente).

Exemplo 1 : Seja X_1, \dots, X_n uma aa $X \sim \text{Bernoulli}(p)$, então

$$f(x_1, \dots, x_n | p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \quad \begin{matrix} I(x_i) \\ \{0, 1\} \end{matrix}$$

$$= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i} \prod_{i=1}^n I(x_i) \quad \begin{matrix} \{0, 1\} \end{matrix}$$

$$= \underbrace{\left(\frac{p}{1-p} \right)^{\sum_{i=1}^n x_i} (1-p)^n}_{g\left(\sum_{i=1}^n x_i | p\right)} \underbrace{\prod_{i=1}^n I(x_i)}_{h(x_1, \dots, x_n)} =$$

Logo, $\sum_{i=1}^n x_i$ é estatística suficiente (19)
para λ .

Exemplo 2: Seja x_1, \dots, x_n a.a. $X \sim \text{Poisson}(\lambda)$,
então

$$f(x_1, \dots, x_n | \lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \quad I(x_i) = \{0, 1, \dots\}$$

$$\frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{\prod_{i=1}^n x_i!} \quad \prod_{i=1}^n I(x_i) = \{0, 1, \dots\}$$

$$\frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{\prod_{i=1}^n x_i!} \quad \prod_{i=1}^n I(x_i) = \{0, 1, \dots\}$$

$$g\left(\sum_{i=1}^n x_i | \lambda\right) \quad h(x_1, \dots, x_n) \quad \text{Logo,}$$

$\sum_{i=1}^n x_i$ é suficiente para λ .

Exemplo 3 : Seja x_1, \dots, x_n a.a $X \sim U(0, \theta)$, (15)

então

$$f(x_1, \dots, x_n | \theta) = \prod_{i=1}^n \frac{1}{\theta} I_{(0, \theta)}(x_i) =$$

$$\frac{1}{\theta^n} \prod_{i=1}^n I_{(0, \theta)}(x_i) \quad \text{Note que}$$

$$\prod_{i=1}^n I_{(0, \theta)}(x_i) = 1 \quad \Leftrightarrow \quad 0 \leq x_i < \theta \quad \forall i.$$

então,

$$0 \leq x_{(1)} \leq x_{(n)} \leq \theta \quad e$$

$$f(x_1, \dots, x_n | \theta) = \underbrace{\frac{1}{\theta^n} I_{(0, \theta)}(x_{(n)})}_{g(x_{(n)} | \theta)} \underbrace{1}_{h(x_1, \dots, x_n)}$$

Logo,

$x_{(n)}$ é suficiente para θ .

Família Exponencial uniparamétrica (18)

Dizemos que a distribuição da variável aleatória X pertence à família exponencial uniparamétrica de distribuição, se podemos escrever sua f.p. ou f.d.p. como

$$f(x|\theta) = h(x) c(\theta) \exp\{w(\theta) t(x)\},$$

$x \in X$ e $\theta \in \Theta$. Além disso, temos

a seguinte família exponencial uniparamétrica de distribuição associada à amostra (X_1, \dots, X_n) a.a. $X \sim f(\cdot|\theta)$.

$$f(x_1, \dots, x_n|\theta) = \prod_{j=1}^n h(x_j) [c(\theta)]^n \exp\left\{w(\theta) \sum_{j=1}^n t(x_j)\right\}.$$

Resultado Importante !!

Note que pelo critério da fatoração

$\sum_{j=1}^n t(x_j)$ é estatística suficiente para

θ .