

Outras distribuições importantes

①

Vamos introduzir alguns modelos para variáveis aleatórias contínuas que serão bastante utilizadas no decorrer do curso.

1 - Distribuição gama

Definição:

Diz-se que uma variável aleatória contínua X tem uma distribuição gama se a fdp

$$\text{de } X \text{ é} \quad f(x; \alpha, \beta) = \begin{cases} \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta} & x \geq 0 \\ 0 & \text{outros} \end{cases} \quad (1)$$

onde os parâmetros α e β satisfazem $\alpha > 0, \beta > 0$,
 $\Gamma(\alpha)$ é a função gama dada por

$$\Gamma(\alpha) = \int_0^\infty e^{-x} x^{\alpha-1} dx, \quad \alpha > 0.$$

Note que $\Gamma(\alpha) = (\alpha-1) \Gamma(\alpha-1)$ e se $\alpha = n$

para um inteiro positivo, $\Gamma(n) = (n-1)!$ e

que $\Gamma(1) = 1$, $\Gamma(\frac{1}{2}) = \sqrt{\pi}$.

Introduzir a notação $X \sim \text{Gamma}(\alpha, \beta)$ ②
 para designar uma variável aleatória dada
 por (1).

A distribuição gama padrão tem $\beta = 1$, de
 forma que a f.d.p. ~~de~~ de uma
 variável aleatória gama padrão é dada

por

$$f(x; \alpha) = \begin{cases} \frac{x^{\alpha-1} e^{-x}}{\Gamma(\alpha)} & x \geq 0 \\ 0 & \text{caso contrário} \end{cases}$$

A média e a variância de uma variável
 aleatória X com distribuição gama ~~padrão~~
 $f(x; \alpha, \beta)$ são

$$E(X) = \mu = \alpha\beta \quad \text{e} \quad \text{Var}(X) = \sigma^2 = \alpha\beta^2.$$

Exemplos gráficos !!!

(outros modelos 1)

$\alpha \leq 1$ funções
decrecantes

$\left\{ \begin{array}{l} \alpha: \text{forma} \\ \beta: \text{escala} \quad (\text{comprimir ou} \\ \text{esticar a} \\ \text{densidade de}) \end{array} \right.$

Aplicar-se a distribuição gama à análise de tempo de vida de equipamentos, de tempo de retorno de mercadorias ou falar e a desfer de confiabilidade.

Exemplo Suponha que o tempo de sobrevivência X em semanas de um camundongo macho relacionado alterontaramente e exposto a 240 rads de radiação tenha distribuição gama com $\alpha = 8$ e $\beta = 15$. O tempo esperado de sobrevida é $E(X) = (8)(15) = 120$ semanas, enquanto $Var(X) = 8(15)^2 = 1800$ e

$$\sigma_X = \sqrt{Var(X)} = \sqrt{1800} = 42,43 \text{ semanas.}$$

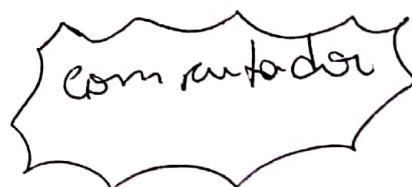
A probabilidade de um camundongo sobreviver entre 60 e 120 semanas é

$$P(60 \leq X \leq 120) = P(X \leq 120) - P(X \leq 60)$$



A probabilidade de um camundongo sobreviver ao menos 30 semanas é

$$P(X \geq 30) = 1 - P(X \leq 30) =$$



Lembrar que é uma distribuição tabelada !!

→ lembrar outra definição!

outra definição: se a variável aleatória X tem densidade dada por

$$f(x; \alpha, \beta) = \frac{\alpha^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} I(x \geq 0)$$

$$\left\{ \begin{array}{l} \alpha = \alpha \\ \frac{1}{\beta} = \beta \end{array} \right.$$

$$E(X) = \frac{\alpha}{\beta} \quad \text{e} \quad \text{Var}(X) = \frac{\alpha}{\beta^2}$$

2- Distribuição exponencial

DEFINIÇÃO

Diz-se que X tem uma distribuição exponencial com parâmetro $\lambda > 0$ se a f.d.p de X for

$$f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & \text{c.c.} \end{cases}$$

Notaremos a notação $X \sim \text{exponencial}(\lambda)$.

Note que a f.d.p exponencial é um caso especial da f.d.p gama em que $\alpha=1$ e

$$\beta = \frac{1}{\lambda}$$

A média e a variância de X são

$$E(X) = \gamma = \alpha\beta = \frac{1}{\lambda} \quad \text{e} \quad \text{Var}(X) = \sigma^2 = \alpha\beta^2 = \frac{1}{\lambda^2}$$

Uma aplicação importante da distribuição exponencial é modelar a distribuição do tempo de vida de um componente.

Exemplos gráficos !! (outros modelos)

O motivo da popularidade dessas aplicações é a propriedade de "falta de memória" da distribuição exponencial.

(5)

Suponha que o tempo de vida de um componente seja distribuído exponencialmente com o parâmetro λ . Assim o componente será colocado em serviço, saímos por um período de t_0 horas e entramos novamente para encontrar o componente ainda funcionando. Neste caso, qual é a probabilidade dele durar ao menos t horas adicionais?

$$\text{ou seja, } P(X \geq t + t_0 | X \geq t_0) =$$

$$\frac{P((X \geq t + t_0) \cap (X \geq t_0))}{P(X \geq t_0)} =$$

$$\frac{P(X \geq t + t_0)}{P(X \geq t_0)} = \frac{1 - P(X \leq t + t_0)}{1 - P(X \leq t_0)} =$$

$$\frac{1 - [1 - e^{-\lambda(t+t_0)}]}{e^{-\lambda t_0}} = \frac{-\lambda(t+t_0)}{e^{-\lambda t_0}} = e^{-\lambda t}$$

$$1 - [1 - e^{-\lambda t_0}] = e^{-\lambda t_0}$$

$= P(X \geq t)$: probabilidade do componente

ter duração t horas. Assim, a distribuição de tempo de vida adicional é exactamente igual à distribuição original de tempo de vida, de forma que em cada ponto no tempo o componente não danificado de desgaste. Em outras palavras, a distribuição do tempo de vida restante é independente da idade atual.

3- Distribuição qui-quadrado

DEFINIÇÃO: Dêja v um inteiro positivo.

Diz-se que uma variável aleatória X possui uma distribuição qui-quadrado com parâmetros v se a f.d.p. de X for a densidade de gama com $\alpha = v$ e $\beta = \frac{1}{2}$. A f.d.p. de uma variável aleatória qui-quadrado será

$$f(x; v) = \begin{cases} \frac{1}{x^{\frac{v}{2}} \Gamma(\frac{v}{2})} & x > 0 \\ 0 & \text{e} \\ & x \geq 0 \end{cases}$$

O parâmetro v é denominado número de graus de liberdade.

graus de liberdade

É a quantidade de informações livres que serão utilizadas para o cálculo de uma estatística.

Exemplo: Variância da amostra

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

\bar{x}
n observações

$\Rightarrow n-1$ observações

→ n-1 graus de liberdade

Usaremos a notação $X \sim X_{\alpha}^{\beta}$.

(7)

A média e a variância de uma variável aleatória X com distribuição X_{α}^{β} são

$$E(X) = \gamma = \alpha \beta = \frac{\sigma}{\alpha} \alpha = \sigma \quad \text{e}$$

$$\frac{\alpha}{\beta} = E(X)$$

$$\text{var}(X) = \sigma^2 = \alpha \beta^2 = \frac{\sigma}{\alpha} 4 = 2\sigma.$$

$$\frac{\alpha}{\beta^2} = \text{var}(X)$$

{ Exemplos gráficos ! ! (outros modelos!)

→ estatística

Teorema: Se as variáveis aleatórias x_i , (8)
 $i = 1, 2, \dots, k$, são normalmente e inde-
pendentemente distribuídas com média
 μ_i e variâncias σ_i^2 , então

$$U = \sum_{i=1}^k \left(\frac{x_i - \mu_i}{\sigma_i} \right)^2 \text{ tem distribuição}$$

qui-quadrado com k graus de liberdade.

Corolário: Se x_1, \dots, x_n é uma amostra
aleatória de uma população X com distri-
buição normal com média μ e variância
 σ^2 , então $U = \sum_{i=1}^n (x_i - \mu)^2 / \sigma^2 \sim \chi_n^2$.

Teorema: Se z_1, z_2, \dots, z_n é uma ~~amostra~~
amostra aleatória de uma população Z
com distribuição $N(0, 1)$, então

$$(i) \bar{z} \sim N(0, \sigma_z^2).$$

(ii) \bar{z} e $\sum_{i=1}^n (z_i - \bar{z})^2$ são variáveis alea-
tórias independentes.

$$(iii) \sum_{i=1}^n (z_i - \bar{z})^2 \sim \chi_{n-1}^2.$$

PROVA (incompleta) (i) resultado que já viemos. ⑨

Al $n = \alpha$, PROVA para $n = \alpha$ no mood
temos que $\bar{z} = \frac{z_1 + z_\alpha}{\alpha}$ e

$$\sum_{i=1}^{\alpha} (z_i - \bar{z})^2 = \left[z_1 - \left(\frac{z_1 + z_\alpha}{\alpha} \right) \right]^2 + \left[z_\alpha - \left(\frac{z_1 + z_\alpha}{\alpha} \right) \right]^2 \\ = \frac{(z_1 - z_\alpha)^2}{4} + \frac{(z_\alpha - z_1)^2}{4} = \frac{(z_\alpha - z_1)^2}{\alpha}.$$

Então, \bar{z} é uma função de $z_1 + z_\alpha$

e $\sum_{i=1}^{\alpha} (z_i - \bar{z})^2$ é uma função de $z_\alpha - z_1$.

Para provar que \bar{z} e $\sum_{i=1}^{\alpha} (z_i - \bar{z})^2$ são independentes, basta mostrar que $z_1 + z_\alpha$ e $z_\alpha - z_1$ são independentes.

Note que $M(z_1) = E \left[e^{t_1 (z_1 + z_\alpha)} \right] = E \left[e^{t_1 z_1 + t_1 z_\alpha} \right]$

$$= E \left[e^{t_1 z_1} e^{t_1 z_\alpha} \right] = E \left[e^{t_1 z_1} \right] E \left[e^{t_1 z_\alpha} \right] = \\ \exp \left\{ \frac{1}{2} t_1^2 \right\} \exp \left\{ \frac{1}{2} t_1^2 \right\} = \exp \left\{ t_1^2 \right\}.$$

$$z_1 + z_\alpha \sim N(0, 2)$$

$$\frac{z_\alpha - z_1}{\sqrt{2}} \sim N(0, 1)$$

e similarmen^t,

$$M_{z_\alpha - z_1}(t_2) = \exp \left\{ t_2^2 \right\}.$$

Note também que

$$M_{z_1 + z_2, z_2 - z_1}^{(t_1, t_2)} = E \left[e^{t_1(z_1 + z_2) + t_2(z_2 - z_1)} \right] =$$

$$= \text{[scratches]} \quad \text{[scratches]}$$

$$E \left[e^{(t_1 - t_2)z_1 + (t_1 + t_2)z_2} \right] =$$

$$E \left[e^{(t_1 - t_2)z_1} e^{(t_1 + t_2)z_2} \right] =$$

$$E \left[e^{(t_1 - t_2)z_1} \right] E \left[e^{(t_1 + t_2)z_2} \right] =$$

$$\exp \left\{ \frac{1}{2} (t_1 - t_2)^2 \right\} \exp \left\{ \frac{1}{2} (t_1 + t_2)^2 \right\}$$

$$= \exp \left\{ t_1^2 \right\} \exp \left\{ t_2^2 \right\}$$

$$= M_{z_1 + z_2}^{(t_1)} M_{z_2 - z_1}^{(t_2)}$$

\Rightarrow Fatoração da função geradora de momentos. Portanto,

$z_1 + z_2$ e $z_2 - z_1$ não independentes.

(iii) resultado útil

(10)

$$\sum_{i=1}^n (x_i - \gamma)^\alpha = \sum_{i=1}^n (x_i - \bar{x})^\alpha + n(\bar{x} - \gamma)^\alpha.$$

Conforme enunciado do teorema,
temos que $\gamma = 0$ e $\beta^\alpha = 1$. Portanto,

$$\sum_{i=1}^n x_i^\alpha = \sum_{i=1}^n (x_i - \bar{x})^\alpha + n\bar{x}^\alpha, \text{ onde}$$

$$\sum_{i=1}^n x_i^\alpha \sim x_n^\alpha \quad \text{e} \quad n\bar{x}^\alpha \sim x_1^\alpha.$$

Como \bar{x} e $\sum_{i=1}^n (x_i - \bar{x})^\alpha$ não independentes entre si,

$$\sum_{i=1}^n (x_i - \bar{x})^\alpha \sim x_{n-1}^\alpha$$

(13a)

O teorema anterior considera uma amostra aleatória proveniente de uma distribuição normal padrão. E se nós desejarmos realizar inferências para μ e σ^2 . Dessa forma,

\rightarrow variação

média

considere x_1, \dots, x_n uma amostra aleatória proveniente de uma distribuição normal com média μ e variação σ^2 , então Z_i , do teorema anterior, seria igual a $\frac{x_i - \mu}{\sigma}$.

Consequências: { Por (i)}

$$\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right) =$$

$$\frac{1}{n\sigma} \left[\sum_{i=1}^n x_i - n\mu \right] = \frac{\bar{x} - \mu}{\sigma} \sim N(0, 1/n)$$

$$\rightarrow \bar{x} \sim N(\mu, \sigma^2/n).$$

{ Por (ii)}

Temos que \bar{Z} e $\sum_{i=1}^n (Z_i - \bar{Z})^2$ são

variações aleatórias independentes. Então,

$$\bar{Z} = \frac{\bar{x} - \mu}{\sigma} \quad e$$

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n \left[\left(\frac{x_i - \mu}{\sigma} \right) - \left(\frac{\bar{x} - \mu}{\sigma} \right) \right]^2$$

$$= \frac{1}{\sigma^2} \sum_{i=1}^n [x_i - (\bar{x} + \gamma)]^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (11)$$

Portanto, $\bar{z} = \frac{\bar{x} - \gamma}{\sigma}$ e $\sum_{i=1}^n (z_i - \bar{z})^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sigma^2}$

são variáveis aleatórias independentes.

Por isso

$$\sum_{i=1}^n (z_i - \bar{z})^2 \sim \chi_{n-1}^2, \text{ então}$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 \sim \chi_{n-1}^2.$$

Corolário

$$\text{se } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (12)$$

é a variância ~~estimativa~~ de uma amostra aleatória proveniente de uma distribuição normal com média μ e variância σ^2 , então

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Note que estes resultados são válidos apenas para populações que seguem distribuição normal. De fato, para nenhuma outra distribuição

(i) a média amostral e a variância amostral não independentes.

(ii) a média amostral tem distribuição exata normal.

4- Distribuição Beta

(13)

DEFINIÇÃO: Dizer que uma variável aleatória X tem distribuição Beta com parâmetros a e b se a f.d.p de X for

$$f(x) = f(x; a, b) = f(x; a, b) =$$

$$\frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1} I_{(0 < x < 1)}, \text{ onde}$$

$$B(a, b)$$

$a > 0$, $b > 0$ e $B(a, b)$ é a função beta dada por

$$B(a, b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx.$$

Note que se $a = b = 1$, temos que a distribuição beta reduz para a distribuição uniforme.

Usaremos a notação $X \sim \text{Beta}(a, b)$.

Comentários: a função geradora de momentos da distribuição Beta não tem uma forma simples. Assim, seus momentos não são obtidos diretamente da sua definição.

parâmetros α e β ^{shape 1} ^{shape 2} definem a forma da distribuição !!

$\alpha = \beta$: a distribuição é simétrica.

$\alpha > \beta$: " " " é assimétrica negativa.

$\alpha < \beta$: " " " " positiva.

exemplos gráficos : distribuição Beta

A média é a variância de uma variável aleatória com distribuições

Beta não

$$E(x) = \frac{a}{a+b} \quad \text{e} \quad \text{Var}(x) = \frac{ab}{(a+b+1)(a+b)^2}$$

por causa do seu domínio $(0,1)$

A distribuição beta normalmente é usada para modelar a proporção, tal como a proporção de um dia de 24 horas em que um indivíduo está dormindo ou a proporção de determinado elemento em um composto químico.

5- Distribuição F de Fisher

Teorema: Sejam v_1 e v_2 duas variáveis

aleatórias independentes, cada uma com distribuição qui-quadrado, com v_1 e v_2 graus de liberdade, respectivamente.

Então, a variável aleatória

$$W = \frac{v_1/v_1}{v_2/v_2} \sim F(v_1, v_2).$$

Suponha que w tem distribuição F de Anedear, com v_1 e v_2 graus de liberdade. Assim, a variável aleatória w tem densidade dada por

$$f(w; v_1, v_2) = \frac{\Gamma\left(\frac{(v_1+v_2)}{2}\right)}{\Gamma\left(\frac{v_1}{2}\right)\Gamma\left(\frac{v_2}{2}\right)} \left(\frac{v_1}{w}\right)^{\frac{v_1}{2}}$$

$$w \sim \frac{(v_1 - \omega)/2}{\left[1 + v_1(w/v_2)\right]^{(v_1+v_2)/2}} I_{(w > 0)}$$

Corolário: Seja x_1, \dots, x_m uma amostra aleatória $N(\mu_1, \sigma^2)$ e y_1, \dots, y_n uma amostra aleatória $N(\mu_2, \sigma^2)$, independentes. Se definirmos

$$s_x^2 = \frac{\sum_{i=1}^m (x_i - \bar{x})^2}{m-1} \quad \text{e} \quad s_y^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}$$

Então, temos que $\frac{(m-1)s_x^2}{\sigma^2} \sim \chi_{m-1}^2$

$\frac{(n-1)s_y^2}{\sigma^2} \sim \chi_{n-1}^2$ e não independentes.

Desta forma,

$$\frac{\frac{(m-1)S_x^2}{f_a}}{(m-1)} \sim F_{(m-1, n-1)}$$

$$\frac{\frac{(n-1)S_y^2}{f_a}}{(n-1)}$$

Resumindo, temos que

$$\frac{S_x^2}{S_y^2} \sim F_{(m-1, n-1)}.$$

A média e a variância de uma variável aleatória com distribuição $F(v_1, v_2)$ não

$$E(W) = \frac{v_2}{v_2 - \alpha} \quad \text{e} \quad \text{Var}(W) = \frac{\alpha v_2^2 (v_1 + v_2 - \alpha)}{v_1 (v_2 - \alpha)^2 (v_2 - 4)}$$

para $v_2 > \alpha$.

Comentários: momentos são obtidos pela definição

$$W = \frac{U/v_1}{V/v_2}, \text{ tal que } U \sim \chi_{v_1}^2 \text{ e } V \sim \chi_{v_2}^2,$$

independentes.

O gráfico típico de uma variável aleatória com distribuição F está na figura a seguir !! (exercícios no comentado - distribuição F).

No tabela VI não dadas os valores f_c ,

tal que

$$P \left\{ F(v_1, v_2) > f_c \right\} = \alpha, \text{ para } \alpha = 0,05$$

e alguns valores de v_1 e v_2 .

Para encontrar os valores inferiores, usa-se a identidade

$$F(v_1, v_2) = \frac{1}{F(v_2, v_1)}$$

(igualdade *)

Exemplo: Considere, por exemplo, $W \sim F(5, 7)$.

Consultando a Tabela VI, $P(F > 3,97) = 0,05$

ou, então, $P(F \leq 3,97) = 0,95$. Digamos, agora, que desejarmos encontrar o valor f_0 , tal que

$$P(F < f_0) = 0,05. \quad \text{Da } \left\{ \begin{array}{l} \text{igualdade} \\ * \end{array} \right\}, \text{ temos}$$

$$0,05 = P\{F(5,7) < f_0\} = P\left(\frac{Y_{F(7,5)}}{f_0} < f_0\right)$$

(18)

$= P\{F(7,5) > \frac{Y_{f_0}}{f_0}\}$, e portanto na Tabela

VI, para $F(7,5)$, obtemos $\frac{Y_{f_0}}{f_0} = 4,88$ e,
portanto, $f_0 = 0,205$.

Usando outra tabela

Exemplos:

(1) (a)

$$P(W \leq 3,97) = 0,95 \text{ ou}$$

$$P(W > 3,97) = 0,05.$$

$$P(W < f_0) = 0,05 = P\left(\frac{1}{W_1} < f_0\right), \text{ onde}$$

$w = \frac{1}{w_1}$, tal que $w \sim F(5, 7)$ e

$$w_1 \sim F(7, 5)$$

usando a
relação
 $F(v_1, v_2) = \frac{1}{F(v_2, v_1)}$

Portanto,

$$P(w_1 > \frac{1}{f_0}) = 0,05, \text{ ou seja},$$

$$P(w_1 < \frac{1}{f_0}) = 0,95, \text{ tal que } w_1 \sim F(7, 5),$$

obtemos na tabela $\frac{1}{f_0} = 4,88 < f_0 = 0,205$.

6- Distribuição t - Student

A distribuição t - student é importante no que se refere à inferência sobre médias populacionais. A obtenção da densidade de estátistica no teorema obtemos:

Teorema: Seja Z uma variável aleatória normal com média 0 e variância 1 e Y uma variável aleatória X_v , com Z e Y independentes. Então, a variável aleatória

$$T = \frac{Z}{\sqrt{Y/v}}$$

tem densidade dada por

$$f(t; v) = \frac{\Gamma\left(\frac{(v+1)}{2}\right)}{\Gamma\left(\frac{v}{2}\right)\sqrt{\pi v}} \left(1 + \frac{t^2}{v}\right)^{-\frac{(v+1)}{2}}, \quad -\infty < t < \infty$$
(19)

Diremos que tal variável tem uma distribuição t-student com v graus de liberdade e a indicaremos por t_v .

Teorema: Se x_1, \dots, x_n é uma amostra aleatória de uma distribuição normal com média μ e variância σ^2 , então $Z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ e

$Y = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2_{n-1}$. Além disso, Z e Y são independentes. Assim,

$$\frac{Z}{\sqrt{Y/(n-1)}} \sim t_{n-1}$$

Resumindo:

$$\frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \quad \sqrt{\frac{(n-1)s^2}{\sigma^2/(n-1)}} =$$

$$= \frac{(\bar{x} - \mu)}{\sqrt{s}} \quad f = \frac{(\bar{x} - \mu)}{s/\sqrt{n}} \sim t_{n-1}$$

(a)

A média e a variância de uma variável aleatória com distribuição t_v são

$$E(T) = 0 \quad \text{se } v > 1 \quad \text{e}$$

$$\text{Var}(T) = \frac{v}{v-2}, \quad \text{se } v > 2.$$

Comentários, momentos são obtidos pela definição

$$T = \frac{\bar{Z}}{\sqrt{1/v}}, \quad \text{tal que } Z \sim N(0,1) \text{ e } Y \sim X_v^2,$$

independente.

Exemplos gráficos : distribuição t



⇒ distribuição simétrica assim como a normal.

Observações adicionais : note que quando $v=1$, a distribuição t -Student reduz para a distribuição Cauchy e que quando o número de graus de liberdade aumenta, a distribuição t -Student se aproxima

da distribuição normal padão.

(2)

Além disso, o quadrado de uma variável aleatória que segue distribuição t_v é uma variável aleatória com distribuição $F(1, v)$.

Por exemplo, se $X \sim t_v$, então $y = X^2 \sim F(1, v)$.

Como essa distribuição é bastante utilizada na prática, existem tabelas fornecendo probabilidades relativas a ela. A tabela V fornece os valores de t_c tal que

$$P(-t_c < T < t_c) = 1 - \alpha, \text{ para alguns}$$

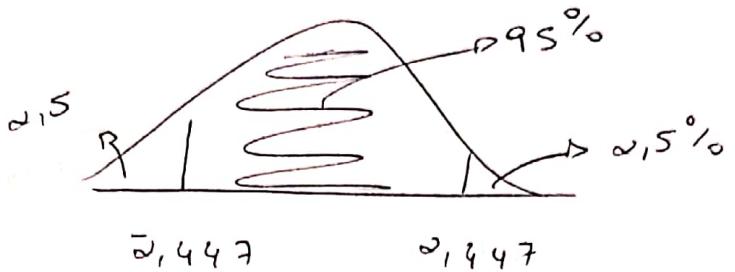
valores de α e de v .

Exemplo: Se $\alpha = 0,10$, então, usando a Tabela V,

$$P(-1,943 < T < 1,943) = 1 - 0,10 = 0,90, \text{ onde}$$

$T \sim t_6$. Além disso, $P(T > 2,447) = 0,025$,

para $P(2,447 < T < 2,447) = 1 - 0,05 = 0,95$.



Observe que, nessa tabela, há uma linha com $\sigma = \infty$, que corresponde a usar os valores da $N(0,1)$.

Para $n > 100$ essa aproximação é muito boa.

A distribuição t é simétrica quanto à assimetria
à distribuição gaussiana, exceto que nesta distri-
bução a probabilidade de valores extremos é
maior. Isto é equivalente a dizer que os outliers
da distribuição são mais prováveis que a de uma
Gaussiana.

A distribuição t é controlada por um parâmetro
tão, σ , chamado grau de liberdade. Este parâmetro
pode assumir qualquer valor positivo, com as
maiores diferenças com respeito à Gaussiana
sendo dadas quando σ é pequeno.

Note que as distribuições gamma, χ^2 e F são assimétricas.

Gamma e χ^2 : são assimétricas positivas
F também

χ^2 $v \rightarrow \infty \rightarrow$ Normal
 $F_{m,n}$ $m, n \rightarrow \infty \rightarrow$ Normal
E assim por diante

Olhar as relações no
quadro

dado em

sala de aula!!
(enviado por email)

{ diretriz também
no Integra. }

