

Teorema Limite Central

Quando os X_i 's são distribuídos normalmente, \bar{X} também é para cada tamanho de amostra n . Porém, os dois últimos experimentos de simulação sugerem que, quando o tamanho da amostra aumenta, independentemente da forma da distribuição da população!

(consideramos uniforme e binomial), (40)
a distribuição amostral de \bar{X} aproxima-se
cada vez mais de uma distribuição normal.
Esse resultado é conhecido como Teorema
Limite Central (TLC).

Teorema fundamental na teoria de inferência
estatística.

Teorema Limite Central

Para amostras aleatórias simples X_1, \dots, X_n ,
retiradas de uma população com média
(valor esperado) μ e variância σ^2 finita, a
distribuição amostral da média \bar{X}
aproxima-se, para n grande, de uma distri-
buição normal, com média μ e variância
 σ^2/n .

Além disso, T_0 também tem aproximada-
mente uma distribuição normal, com
média $n\mu$ e variância $n\sigma^2$.

quanto maior o valor de n , melhor a aproximação.

A rapidez dessa convergência depende da distribuição da população da qual a amostra é retirada. Se a população original tem uma distribuição próxima da normal, a convergência é rápida; se a população original se afasta muito de uma normal, a convergência é mais lenta, ou seja, necessitamos de uma amostra maior para que \bar{X} tenha uma distribuição aproximadamente normal. Para amostras da ordem de 30 ou 50 elementos a aproximação pode ser considerada boa (razável).

Exemplo: considere uma máquina que enche pacotes cujo peso segue uma distribuição $N(500, 100)$. Colhendo-se uma amostra de 100 pacotes e pesando-os, pelo que foi dito acima, \bar{X} terá uma distribuição normal com média 500 e variância $100/100 = 1$. Logo, se a máquina estiver regulada, a probabilidade de

encontrarmos a média de 100 pacotes (42)
aferindo de 500g de menos de 2 grammas será

$$P(|\bar{X} - 500| \leq 2) = P(498 \leq \bar{X} \leq 502) =$$

$$P(-2 \leq Z \leq 2) \approx 95\%$$

ou seja, dificilmente 100 pacotes terão uma
média fora do intervalo (498, 502). Como 100
pacotes apresentem uma média fora desse intervalo,
isto, podemos considerar como um evento raro,
e não razoável supor que a máquina esteja
funcionando corretamente.

Condição: Se X_1, \dots, X_n for uma amostra
aleatória simples da população X , com média
 μ e variância σ^2 finita, e $\bar{X} = \frac{X_1 + \dots + X_n}{n}$,
então

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

observe também que podemos escrever
da seguinte forma

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1).$$

Chamemos de " e " a variável aleatória ⁽⁴³⁾
que mede a diferença entre a estatística
 \bar{X} e o parâmetro μ , isto é, $e = \bar{X} - \mu$
e e é chamado de erro amostral da
média. Então, temos o seguinte corolário.

Corolário: A distribuição de e aproxima-se
de uma distribuição normal com
média 0 e variância σ^2/n , isto é,

$$\frac{\sqrt{n} e}{\sigma} \sim N(0, 1) .$$

Outras aplicações do Teorema Limite Central

Distribuição Amostral de uma proporção

Vamos ~~considerar~~ considerar uma população em que a proporção de elementos portadores de certa característica é p .

Logo, podemos definir uma variável aleatória (44)
 X , da seguinte maneira:

$$X = \begin{cases} 1, & \text{se o indivíduo for portador da característica} \\ 0, & \text{se o indivíduo não for portador da característica} \end{cases}$$

Assim, $\mu = E(X) = p$ e $\sigma^2 = \text{Var}(X) = p(1-p)$.

Retirada uma amostra aleatória simples X_1, \dots, X_n dessa população, e indicando por Y o total de indivíduos portadores da característica na amostra, ~~ou seja~~
ou seja, $Y = X_1 + \dots + X_n$, onde cada X_i tem distribuição de Bernoulli, com média $\mu = p$, variância $\sigma^2 = p(1-p)$ e são independentes. Podemos escrever

$$Y = n\bar{X} \sim \text{binomial}(n, p).$$

Considere X_1, \dots, X_n iid $X \sim \text{Bernoulli}(p)$
 Mostre que $T_0 = X_1 + \dots + X_n = \sum_{i=1}^n X_i \sim \text{Binomial}(n, p)$.

PROVA:

Sabemos que se $X \sim \text{Bernoulli}(p)$ então

$$m_X(t) = 1 - p + e^t p. \quad \text{Assim como,}$$

$$m_{T_0}(t) = m_{\sum_{i=1}^n X_i}(t) = \left[m_X(t) \right]^n, \quad \text{pois}$$

X_1, \dots, X_n são v.a.'s iid. Assim,

$$m_{T_0}(t) = (1 - p + e^t p)^n \quad \text{q.d.}$$

Vimos em sala de aula que a fgm para uma v.a. que tem distribuição binomial(n, p) é dada por

$$(1 - p + e^t p)^n.$$

Portanto, $T_0 \sim \text{Binomial}(n, p)$.

Vamos definir por \hat{p} a proporção de indivi- (45)
duos portadores da característica na amostra,
isto é,

$$\hat{p} = Y/n \quad \text{Então,}$$

$$P(Y = k) = P\left(Y/n = k/n\right) = P\left(\hat{p} = k/n\right),$$

ou seja, a distribuição amostral de \hat{p} é
obtida da distribuição de Y .

Nota que $Y = n\bar{X}$, mas pelo TLC,

\bar{X} terá distribuição aproximadamente normal,
com média p e variância $\frac{p(1-p)}{n}$, ou seja,
 μ σ^2/n

$\bar{X} \sim N\left(p, \frac{p(1-p)}{n}\right)$. Logo, a transforma-
ção $Y = n\bar{X}$ terá a distribuição

$$Y \sim N(np, np(1-p)).$$

(f.g.m)
ou
(função
característica)

Observe que \bar{X} é a média variável (46)
 \hat{p} e, desse modo, para n grande podemos
considerar a distribuição amostral de p
como aproximadamente normal:

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right).$$

Exemplo: suponha que $p = 30\%$ dos estudantes
de uma escola sejam mulheres. Colhemos
uma a.a.s. de $n = 10$ estudantes e calcula-
mos \hat{p} = proporção de mulheres na amostra.
Qual a probabilidade de que \hat{p} difira
de p em menos de $0,01$? Temos que
esta probabilidade é dada por

$$P(|\hat{p} - p| < 0,01) = P(-0,01 < \hat{p} - p < 0,01),$$

mas $\hat{p} - p \sim N\left(0, \frac{p(1-p)}{n}\right)$. Como $p = 0,3$,

$$\text{temos que } \text{Var}(\hat{p}) = \frac{p(1-p)}{n} = \frac{0,3 \times 0,7}{10} = 0,021.$$

portanto, a probabilidade pedida é
igual a

(47)

$$P\left(\frac{-0,01}{\sqrt{0,021}} < Z < \frac{0,01}{\sqrt{0,021}}\right) = P(-0,07 < Z < 0,07) =$$

0,056, onde

$Z \sim N(0, 1)$.